

Aparcamiento autónomo

Evaluación comparativa de controladores clásicos, MPC y DRL

José Antonio García Campanario
Andrés Martínez Márquez
Fernando Román Hidalgo

Control en Vehículos

26 de mayo de 2026

Idea central del trabajo

Problema

El aparcamiento autónomo exige seguimiento preciso a baja velocidad, con restricciones no holonómicas, obstáculos cercanos y tolerancias reducidas en posición y orientación.


Arquitectura propuesta

Se divide la tarea en dos fases:

- ➊ **Aproximación al aparcamiento:** controladores de seguimiento.
- ➋ **Maniobra final:** agente de Deep Reinforcement Learning.

Mensaje clave: comparar precisión, suavidad y coste computacional.

Arquitectura general del sistema



- Los controladores clásicos llevan el vehículo hasta la zona de transición.
- El agente DRL ejecuta la maniobra final de aparcamiento.
- Todos los controladores se comparan sobre el mismo modelo y escenario.

Modelo de bicicleta:

$$x = [X \quad Y \quad \theta]^T, \quad u = [v \quad \delta]^T$$

$$\dot{x} = \begin{bmatrix} v \cos \theta \\ v \sin \theta \\ \frac{v}{L} \tan \delta \end{bmatrix}$$

$$L = 2,8 \text{ m}$$

Restricciones físicas:

$$-5 \leq v \leq 5 \text{ m/s}$$

$$-\frac{\pi}{4} \leq \delta \leq \frac{\pi}{4}$$

Hipótesis

Modelo adecuado para baja velocidad, sin dinámica lateral de neumáticos ni deslizamiento significativo.

Controladores evaluados

Controlador	Tipo	Idea principal
Pure Pursuit	Geométrico	Sigue un punto objetivo a distancia de anticipación.
Stanley	Geométrico	Combina error lateral y error de orientación.
LQR	Óptimo lineal	Realimentación óptima local sobre modelo linealizado.
MPC adaptativo	Predictivo lineal	Optimiza con modelo lineal actualizado en línea.
NMPC	Predictivo no lineal	Optimiza usando directamente el modelo no lineal.
TD3 / SAC / DDPG	DRL	Política aprendida para la maniobra final de aparcamiento.

Criterio de comparación

No se busca solo mínimo error, sino equilibrio entre precisión, suavidad, robustez y coste computacional.




Figura 1: Escenario de aparcamiento y lidar del vehículo.

Configuración:




- Entorno MATLAB/Simulink – UE.
- Trayectoria de referencia común.
- Plaza detectada por geométrica.
- Conmutación posterior hacia DRL.

Métricas:

- RMSE lateral.
- Error lateral máximo.
- Error lateral medio.
- RMSE de orientación.
- Esfuerzo y suavidad de dirección.
- Tiempo de cómputo.

Comparativa global de seguimiento

Comparativa de controladores



Resultados cuantitativos de seguimiento

Controlador	RMSE lat. [m]	Error max. [m]	Error medio [m]	RMSE heading [deg]
Pure Pursuit	0.7408	1.5890	0.4974	9.67
Stanley	1.8519	3.7550	1.2332	12.67
LQR	0.2313	0.4580	0.1379	3.50
MPC adaptativo	0.0061	0.0203	0.0030	0.77
Non Linear MPC	0.0062	0.0169	0.0032	0.79

Lectura técnica

Los dos MPC son claramente superiores en precisión. El MPC adaptativo obtiene prácticamente el mismo RMSE que el NMPC, pero con un coste computacional mucho menor.

Análisis individual: LQR frente a MPC

Métricas de seguimiento - LQR




Figura 3: LQR

Métricas de seguimiento - MPC Adaptive




Figura 4: MPC adaptativo

Análisis individual: NMPC, Pure Pursuit y Stanley




Figura 5: NMPC




Figura 6: Pure Pursuit




Figura 7: Stanley

- NMPC alcanza precisión similar al MPC adaptativo, pero con mayor coste.
- Pure Pursuit es suave, pero recorta y oscila más en curva.
- Stanley presenta el peor seguimiento en este escenario, posiblemente por sensibilidad al punto delantero y a la ganancia lateral.

Coste computacional de controladores

Controlador	Tiempo total [s]	Llamadas	Tiempo por paso
NMPC	13.680	3240	≈ 4.222 ms
MPC adaptativo	0.172	3232	≈ 53.2 μ s
Pure Pursuit	0.154	2863	≈ 53.8 μ s
Stanley	0.089	2905	≈ 30.6 μ s
LQR	0.080	3176	$\approx$ 25.2 μ s

Conclusión de coste

El NMPC es el más costoso. El MPC adaptativo mantiene precisión prácticamente equivalente al NMPC, pero con un tiempo por paso del orden de microsegundos.

Controlador	RMSE lat. [m]	Tiempo/paso	Valoración
LQR	0.2313	25.2 μ s	Muy rápido, precisión media
MPC adaptativo	0.0061	53.2 μ s	Mejor compromiso global
NMPC	0.0062	4.222 ms	Muy preciso, coste alto
Pure Pursuit	0.7408	53.8 μ s	Simple, pero menos preciso
Stanley	1.8519	30.6 μ s	Rápido, pero peor ajuste

Resultado principal

Para la fase de aproximación, el **MPC adaptativo** es el controlador más equilibrado: precisión de nivel NMPC con coste cercano a controladores geométricos.

Fase DRL: maniobra final de aparcamiento

Observaciones del agente:

- Error longitudinal X_e .
- Error lateral Y_e .
- Error angular θ_e .
- Nube de puntos Lidar 3D
(simplificada en un vector de distancias radiales)

Acción:

$$a \in [-1, 1] \quad \Rightarrow \quad \delta \in \left[-\frac{\pi}{4}, \frac{\pi}{4}\right]$$

Recompensa:

$$r_t = 2e^{-(0,05X_e^2 + 0,04Y_e^2)} + 0,5e^{-40\theta_e^2} - 0,05\delta^2 + 100f_t - 50g_t$$

- f_t : aparcamiento exitoso.
- g_t : colisión o salida de la zona.
- Penalización por dirección brusca.

Agente DRL	Coste computacional total [s]
DDPG	0.608
TD3	0.659
SAC	0.623

Interpretación

TD3 presenta el mayor coste computacional medido, seguido de SAC y DDPG. Sin embargo, la selección final del agente no debe depender únicamente de este factor, sino que debe evaluarse en equilibrio con la tasa de éxito, la precisión final, la estabilidad y la suavidad de la acción de control.

Discusión: comparación teórica de agentes DRL

Agente	Filosofía y Exploración	Ventajas clave	Limitaciones en el entorno
DDPG	Off-Policy y Determinista. Confía en ruido externo añadido para romper la política fija.	Estructura simple, bajo coste computacional por paso y convergencia eficiente en espacios sencillos.	Tiende a estancarse en una recompensa media plana si la geometría del entorno exige maniobras complejas.
TD3	Off-Policy y Determinista. Evolución de DDPG con ruido suavizado y retraso en actualizaciones.	Alta estabilidad de entrenamiento. Los <i>Twin Critics</i> evitan la sobreestimación del valor Q, mitigando oscilaciones.	Exploración menos flexible ante asimetrías geométricas estrictas. Puede ralentizar el aprendizaje en fases iniciales.
SAC	Off-Policy y Estocástico. Maximiza la recompensa junto a la entropía (incertidumbre) de las acciones.	Excelente eficiencia de datos y robustez. Fuerza la búsqueda de alternativas autónomas óptimas en entornos altamente restrictivos.	Incentivar la aleatoriedad puede traducirse en acciones de control excesivamente bruscas o discontinuas.

Apunte técnico sobre el aprendizaje

Al incentivar la aleatoriedad, **SAC evita que la política colapse en óptimos locales** y acelera el descubrimiento de la maniobra óptima frente a los enfoques deterministas.

Discusión: comparación de métricas de validación (100 episodios)

Agente	Error Posición (m)	Error Orientación (grados)	Tasa de Éxito	Tasa de Siniestralidad	Tiempo Medio de Maniobra (pasos)	Esfuerzo Medio Control (rad/paso)
DDPG	0.061	2.120°	59.0 %	41.0 %	42.6	0.0767
TD3	0.055	2.177°	83.0 %	17.0 %	41.3	0.0693
SAC	0.067	1.547°	85.0 %	15.0 %	36.8	0.1948

Conclusión técnica de validación

Los resultados cuantitativos actualizados consolidan la superioridad de **SAC** en la eficiencia global de la maniobra al lograr la mayor **tasa de éxito** y el menor **tiempo medio de maniobra** con una excelente precisión; no obstante, su exploración estocástica induce un esfuerzo de control en la dirección notablemente más agresivo (**0.1948 rad/paso**). Por su parte, **TD3** demuestra una precisión excepcional y mantiene el comportamiento más suave en el volante (**0.0693 rad/paso**), posicionándose como una alternativa altamente competitiva para el confort del pasajero.

Discusión: control clásico, MPC y DRL

Familia	Ventajas	Limitaciones	Uso recomendado
Geométricos	Simple y rápidos	Sensibles a geometría y ajuste	Baseline o sistemas simples
LQR	Muy eficiente	Validez local	Seguimiento con errores moderados
MPC adaptativo	Preciso y eficiente	Requiere modelo actualizado	Aproximación principal
NMPC	Modelo no lineal completo	Coste elevado	Maniobras muy exigentes
DRL	Aprende estrategias complejas	Difícil de verificar	Aparcamiento final

Conclusión técnica

La solución más coherente es híbrida: **MPC adaptativo para aproximación y DRL para la maniobra final.**

Conclusiones

- Se ha implementado una arquitectura de aparcamiento autónomo en dos fases:
 - aproximación mediante controladores clásicos/MPC,
 - maniobra final mediante DRL.
- La comparación experimental muestra que:
 - MPC adaptativo y NMPC son los más precisos;
 - LQR es el más rápido;
 - Pure Pursuit y Stanley son simples, pero menos precisos en este escenario;
 - MPC adaptativo ofrece el mejor equilibrio precisión–coste.
- TD3 y SAC validan el uso de aprendizaje por refuerzo continuo para la maniobra final.

Perspectiva de optimización

El desafío radica en **aprovechar la exploración estocástica de SAC** sin sacrificar el confort. Como línea futura, planteamos combinar la penalización del ángulo máximo (término δ^2) con un nuevo parámetro sobre la **derivada de la acción** ($\dot{\delta}^2$), penalizando directamente la tasa de cambio de la dirección para mitigar por completo los volantazos en su implementación real.

Gracias

Preguntas